

گزارش کار تمرین سری دوم درس یادگیری ژرف دکتر تشنه‌لب

کسری عطار کاشانی

Kasra Attar Kashani

بخش اول :

جواب سوال اول : (1)

ساختار داخلی: شبکه LSTM دارای سه گیت ورودی، خروجی و فراموشی دارد و یک وضعیت سلول مجزا از Hidden State است. در مقابل GRU معماری ساده‌تری دارد و تنها از دو گیت (بروزرسانی و بازنشانی) استفاده می‌کند و Cell State را با Hidden State ترکیب کرده است.

سرعت و حافظه محاسباتی: به دلیل داشتن پارامترها و گیت‌های کمتر آموزش GRU سریع‌تر است و حافظه کمتری مصرف می‌کند.

عملکرد روی داده‌ها: LSTM در مدل‌سازی وابستگی‌های بسیار طولانی به دلیل وجود مسیر مستقیم Cell State اغلب بهتر عمل می‌کند. با این وجود در دیتاست‌های کوچک‌تر GRU به دلیل پیچیدگی کمتر و مقاومت بهتری در برابر Overfitting نشان می‌دهد.

پشته کردن یا روی هم قرار دادن چندین لایه Stacked: باعث ایجاد شبکه‌های عمیق‌تر در محور فضا می‌شود. این کار به مدل اجازه می‌دهد تا ویژگی‌های سلسله‌مراتبی و پیچیده‌تری را از دنباله زمانی استخراج کند. لایه‌های پایین‌تر الگوهای کوتاه‌مدت و نوسانات سریع را یاد می‌گیرند، در حالی که لایه‌های بالاتر الگوهای بلندمدت را درک می‌کنند.

جواب سوال دوم : (2)

در شبکه‌های RNN استاندارد در طول پس‌انتشار گرادینان خطا نسبت به وزن‌ها از طریق ضرب ماتریس‌های وزن در هر گام زمانی منتشر می‌شود. اگر توالی طولانی باشد این ضرب‌های پشت‌سرهم به صورت ریاضی به شکل زیر است:

$$\frac{\partial L}{\partial h^{(1)}} = \frac{\partial L}{\partial h^{(T)}} \cdot \prod_{t=2}^T \frac{\partial h^{(t)}}{\partial h^{(t-1)}}$$

اگر مقادیر وزن‌ها کوچک‌تر از ۱ باشند، این حاصل ضرب به سرعت به صفر میل می‌کند (محوشدگی) و اگر بزرگ‌تر از ۱ باشند، به بی‌نهایت میل می‌کند (انفجار).

LSTM این مشکل را با دو مکانیزم اصلی حل می‌کند:

۱. **Cell State و مسیر مستقیم گرادینان:** در LSTM یک مسیر اضافه وجود دارد که از طریق جمع بروزرسانی می‌شود:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

گرادیان از طریق این مسیر بدون ضرب ماتریسی جریان می‌یابد. این مکانیزم که به آن Constant Error Carousel گفته می‌شود اجازه می‌دهد گرادیان از لایه‌های دور بدون کاهش شدید برگردد.

۲. **گیت فراموشی (Forget Gate):** این گیت مقدار بین ۰ و ۱ تولید می‌کند و تعیین می‌کند چقدر از cell state قبلی حفظ شود. در backprop، گرادیان به شکل زیر از طریق این گیت منتشر می‌شود:

$$\frac{\partial c_t}{\partial c_{t-1}} = f_t$$

وقتی f_t تقریباً یک باشد، گرادیان بدون افت منتقل می‌شود. این در تضاد با RNN ساده است که در آن ضرب ماتریسی باعث محو شدگی می‌شود.

جواب سوال سوم: (3)

بله، امکان‌پذیر است، اما چالش اصلی وابستگی زمانی (sequential dependency) است:

برخلاف CNN که می‌توان هر بخش از تصویر را به صورت موازی پردازش کرد در LSTM حالت پنهان h_t به h_{t-1} وابسته است. یعنی نمی‌توان گام‌های زمانی را به صورت موازی محاسبه کرد که این یک محدودیت ذاتی معماری است.

روش‌های اجرایی موازی‌سازی:

۱. **موازی‌سازی داده (Data Parallelism):** رایج‌ترین روش Batch. داده‌ها بین چند GPU تقسیم می‌شود. هر GPU یک نسخه کامل مدل دارد و روی زیرمجموعه‌ای از داده‌ها آموزش می‌بیند. گرادیان‌ها در پایان هر epoch جمع‌آوری و میانگین گرفته می‌شوند. این روش برای LSTM به خوبی کار می‌کند چون هر sample کامل است.

۲. **موازی‌سازی مدل (Model Parallelism):** در شبکه‌های Stacked LSTM، می‌توان لایه‌های مختلف را روی GPUهای متفاوت قرار داد. لایه ۱ روی GPU1 پردازش می‌کند و خروجی‌اش را به لایه ۲ روی GPU2 منتقل می‌کند. اما این روش Pipeline overhead ایجاد می‌کند.

۳. **Truncated BPTT:** توالی‌های طولانی به بخش‌های کوچک‌تر تقسیم می‌شوند. هر بخش می‌تواند روی GPU جداگانه‌ای پردازش شود. این کار موازی‌سازی در محور زمان را تا حدی ممکن می‌کند.

بخش دوم:

تحلیل داده‌های کووید-۱۹ با LSTM و GRU

در این بخش دو مدل LSTM و GRU تک‌لایه با ۳۲ unit از صفر با NumPy پیاده‌سازی شدند. داده‌های روزانه کووید-۱۹ ایران بارگذاری و با MinMaxScaler نرمال‌سازی و به توالی‌های ۱۲ گامه برای پیش‌بینی سومین گام بعدی تبدیل شدند (تقسیم ۸۰-۲۰). تفاوت معماری دو مدل در لایه FC است: در LSTM تنها آخرین hidden state وارد FC می‌شود اما در GRU خروجی تمام توالی‌ها به FC ارسال می‌گردد. آموزش با الگوریتم SGD و Backpropagation کامل انجام شد؛ نتایج نشان داد که

LSTM - Test MSE: 0.028734

GRU - Test MSE: 0.007068

پارامترهای شبکه:


پارامتر	مقدار
Hidden Units	32
Sequence Length	12
Lookahead	3 گام
Learning Rate	0.001
Epochs	30
Optimizer	SGD
Loss	MSE
Train/Test Split	80/20

(کد مربوط به این بخش در < Cell 2 > و < Cell 3 > فایل کد در فایل ارائه هست)

خروجی:

سکون‌های موجود در فایل: [205]

```
-----  
205  
0 385  
1 523  
2 835  
3 586  
4 591  
-----
```





X_train shape: (524, 12, 1)
y_train shape: (524, 1)

```
=====
```

مدل	Test MSE
LSTM	0.028734
GRU	0.007068

```
=====
```



=====

روی داده‌های کووید-۱۹ SGD از صفر با LSTM آموزش

=====

LSTM - Epoch 0, Train Loss (MSE): 0.036972
LSTM - Epoch 5, Train Loss (MSE): 0.028639
LSTM - Epoch 10, Train Loss (MSE): 0.027615
LSTM - Epoch 15, Train Loss (MSE): 0.026542
LSTM - Epoch 20, Train Loss (MSE): 0.025433
LSTM - Epoch 25, Train Loss (MSE): 0.024268

LSTM - Test MSE: 0.028734

=====

روی داده‌های کووید-۱۹ SGD از صفر با GRU آموزش

=====

GRU - Epoch 0, Train Loss (MSE): 0.043901
GRU - Epoch 5, Train Loss (MSE): 0.018622
GRU - Epoch 10, Train Loss (MSE): 0.011248
GRU - Epoch 15, Train Loss (MSE): 0.007472
GRU - Epoch 20, Train Loss (MSE): 0.005545
GRU - Epoch 25, Train Loss (MSE): 0.004559

GRU - Test MSE: 0.007068

روابط بخش 2:

LSTM (Forward)

$$\begin{aligned}f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f) \\i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i) \\ \tilde{c}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c) \\o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o) \\c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\h_t &= o_t \odot \tanh(c_t) \\\hat{y} &= W_{fc}h_T + b_{fc} \\L &= (\hat{y} - y)^2\end{aligned}$$

: LSTM Backward (BPTT)

$$\frac{\partial L}{\partial W_{fc}} = 2(\hat{y} - y) \cdot h_T^\top$$

$$\delta h_T = W_{fc}^\top \cdot 2(\hat{y} - y)$$

در هر گام t از آخر به اول:

$$\begin{aligned}\delta o_t &= \delta h_t \odot \tanh(c_t), \delta o_t^{raw} = \delta o_t \odot o_t(1 - o_t) \\ \delta c_t &= \delta h_t \odot o_t \odot (1 - \tanh^2(c_t)) + \delta c_{t+1} \\ \delta f_t &= \delta c_t \odot c_{t-1}, \delta f_t^{raw} = \delta f_t \odot f_t(1 - f_t) \\ \delta i_t &= \delta c_t \odot \tilde{c}_t, \delta i_t^{raw} = \delta i_t \odot i_t(1 - i_t) \\ \delta \tilde{c}_t &= \delta c_t \odot i_t, \delta \tilde{c}_t^{raw} = \delta \tilde{c}_t \odot (1 - \tilde{c}_t^2) \\ \delta W_{f+} &= \delta f_t^{raw} [h_{t-1}, x_t]^\top, \dots \text{ (مشابه } W_i, W_c, W_o) \\ \delta h_{t-1} &= [W_f^\top \delta f_t^{raw} + W_i^\top \delta i_t^{raw} + W_c^\top \delta \tilde{c}_t^{raw} + W_o^\top \delta o_t^{raw}]_{:H} \\ \delta c_{t-1} &= \delta c_t \odot f_t\end{aligned}$$

: GRU (Forward)

$$\begin{aligned}z_t &= \sigma(W_z[h_{t-1}, x_t] + b_z) \\ r_t &= \sigma(W_r[h_{t-1}, x_t] + b_r) \\ \tilde{h}_t &= \tanh(W_h[r_t \odot h_{t-1}, x_t] + b_h) \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \\ \hat{y} &= W_{fc}[h_1 \parallel h_2 \parallel \dots \parallel h_T] + b_{fc}\end{aligned}$$

: GRU Backward

$$\begin{aligned}\frac{\partial L}{\partial h_t} &= \frac{\partial L}{\partial \hat{y}} \cdot W_{fc}^\top + \delta h_{t+1, \text{prop}} \\ \delta z_t &= \delta h_t \odot (\tilde{h}_t - h_{t-1}), \delta z_t^{raw} = \delta z_t \odot z_t(1 - z_t) \\ \delta \tilde{h}_t &= \delta h_t \odot z_t, \delta \tilde{h}_t^{raw} = \delta \tilde{h}_t \odot (1 - \tilde{h}_t^2) \\ \delta r_t &= (W_h^\top \delta \tilde{h}_t^{raw})_{:H} \odot h_{t-1}, \delta r_t^{raw} = \delta r_t \odot r_t(1 - r_t) \\ \delta W_{z+} &= \delta z_t^{raw} [h_{t-1}, x_t]^\top, \delta W_{r+} = \delta r_t^{raw} [h_{t-1}, x_t]^\top, \delta W_{h+} = \delta \tilde{h}_t^{raw} [r_t \odot h_{t-1}, x_t]^\top\end{aligned}$$

بخش سوم:

تشخیص فعالیت‌های انسانی (HAR70) با Stacked LSTM

دیتاست HAR70+ شامل داده‌های سنسور شتاب‌سنج از ۱۸ نفر بالای ۷۰ سال است که ۷ نوع فعالیت روزانه را انجام می‌دهند. معماری Stacked LSTM دو لایه با ۶۴ و ۳۲ unit از صفر پیاده‌سازی شد؛ خروجی لایه اول به عنوان ورودی لایه دوم استفاده شده و آخرین hidden state لایه دوم به لایه کلاسیفایر (Softmax) با ۷ کلاس داده می‌شود. داده‌ها به توالی‌های ۵۰ گامه با گام ۲۵ تقسیم شدند و آموزش با SGD و Cross-Entropy Loss انجام گرفت.

(کد مربوط به این بخش در < Cell 4 > و < Cell 5 > فایل کد در فایل ارائه هست)


پارامترهای شبکه:

پارامتر	مقدار
LSTM Layer 1 Units	64
LSTM Layer 2 Units	32
Time Steps	50
Step Size	25
Learning Rate	0.005
Epochs	5
Optimizer	SGD
Loss	Cross-Entropy
Train/Test Split	80/20

خروجی:

HAR70+ Dataset shape before cleaning: (2259597, 8)

HAR70+ Dataset shape after dropping text columns: (2259597, 7)



Training sequences: (72305, 50, 6)

Testing sequences: (18077, 50, 6)

Number of classes: 7

Sample prediction probabilities shape: (7, 1)

لیبل‌های اصلی: [7 6 5 4 3 2 0]

تعداد کلاس‌ها (واقعی): 7

mapped: [0 1 2 3 4 5 6] نمونه‌ای از لیبل‌های

Stacked LSTM روی HAR70+ شروع آموزش

(از ۳۰۰۰ نمونه تصادفی برای سرعت استفاده می‌شود)


Epoch 1/5 | Loss: 1.5356 | Test Accuracy: 49.50%

Epoch 2/5 | Loss: 1.4013 | Test Accuracy: 49.50%

Epoch 3/5 | Loss: 1.3810 | Test Accuracy: 49.50%

Epoch 4/5 | Loss: 1.3723 | Test Accuracy: 49.50%

Epoch 5/5 | Loss: 1.3672 | Test Accuracy: 49.50%



بخش چهارم:

پیش‌بینی دما با استفاده از Bidirectional LSTM و Bidirectional GRU

در این بخش دو مدل Bidirectional LSTM و Bidirectional GRU تک‌لایه با ۳۲ unit از صفر پیاده‌سازی شدند. هر مدل توالی را یک‌بار از ابتدا به انتها (Forward) و یک‌بار از انتها به ابتدا (Backward) پردازش کرده و نتایج هر دو جهت را برای هر گام زمانی concat می‌کند. خروجی مدل به شکل توالی کامل از hidden state ها به لایه FC داده می‌شود تا سومین گام زمانی بعدی پیش‌بینی شود. داده‌های دمای سری زمانی پس از نرمال‌سازی به توالی‌های ۱۲ گامه تبدیل شدند و آموزش با SGD انجام گرفت.

(کد مربوط به این بخش در > Cell 6 < فایل کد در فایل ارائه هست)

پارامترهای شبکه:

پارامتر	مقدار
Hidden Units	32
Sequence Length	12
Look ahead	3 گام
Learning Rate	0.001
Epochs	10
Optimizer	SGD
Loss	MSE
Train/Test Split	80/20

خروجی:

...

X_temp shape: (321, 12, 1), y_temp shape: (321, 1)
Train samples: 256 | Test samples: 65


```
=====
روی داده‌های دما Bidirectional LSTM آموزش
=====
Bi-LSTM (قبل از آموزش) تست اولیه: 0.050568
Bi-LSTM Epoch 0 | Loss: 0.135558
Bi-LSTM Epoch 2 | Loss: 0.016802
Bi-LSTM Epoch 4 | Loss: 0.014136
Bi-LSTM Epoch 6 | Loss: 0.013727
Bi-LSTM Epoch 8 | Loss: 0.013295
```

Bi-LSTM Test MSE: 0.025726

```
=====
روی داده‌های دما Bidirectional GRU آموزش
=====
Bi-GRU Epoch 0 | Loss: 0.040513
Bi-GRU Epoch 2 | Loss: 0.010154
Bi-GRU Epoch 4 | Loss: 0.010102
Bi-GRU Epoch 6 | Loss: 0.010076
Bi-GRU Epoch 8 | Loss: 0.010051
```



Bi-GRU Test MSE: 0.015369

```
=====
مدل                                Test MSE
=====
Bi-LSTM                            0.025726
Bi-GRU                             0.015369
=====
```



Bi-LSTM initialized. Temperature prediction for sample 0: 0.013580660738793996

Test MSE	
Bi-LSTM	0.025726
Bi-GRU	0.015369



بخش پنجم:

بازسازی سیگنال با LSTM Autoencoder


در این بخش یک سری زمانی مصنوعی با طول ۳۰ نمونه از فرمول

$$y(t) = \sin(t) + 0.5 \cos(2t)$$

در بازه $[0, 4\pi]$ تولید شد و رسم شد. معماری LSTM Autoencoder از دو بخش انکودر و دیکودر تشکیل شده است. انکودر توالی ورودی را به یک بردار ویژگی فشرده با ابعاد کوچکتر تبدیل می‌کند و دیکودر آن را گام به گام بازسازی می‌کند. لایه RepeatVector بردار فشرده انکودر را به تعداد گام‌های زمانی تکرار می‌کند تا دیکودر بداند برای هر timestep چه اطلاعاتی در اختیار دارد. لایه TimeDistributed نیز یک Dense را برای هر گام زمانی به صورت مستقل اعمال می‌کند. مدل پس از ۵۰۰ epoch آموزش توانست سیگنال اصلی را با دقت بسیار بالا بازسازی کند که در نمودار مقایسه، خط چین قرمز (بازسازی شده) تقریباً کاملاً با سیگنال آبی (اصلی) منطبق است.

(کد مربوط به این بخش در < Cell 7 > فایل کد در فایل ارائه هست)

خروجی:



بخش ششم:

Ensemble Learning با ترکیب LSTM و GRU (دیتاست ECG)

در این بخش یک مدل Ensemble از ترکیب وزن‌دهی‌شده LSTM و GRU برای پیش‌بینی سیگنال ECG پیاده‌سازی شد؛ هر مدل به صورت مستقل آموزش می‌بیند و آخرین hidden state هر کدام از طریق یک لایه Dense مشترک پردازش شده، سپس با ضرایب α برای LSTM و ضرایب β برای GRU با هم جمع می‌شوند:

$$\hat{y} = \alpha \cdot \text{Dense}(h_{LSTM}) + \beta \cdot \text{Dense}(h_{GRU})$$

نوآوری اصلی این بخش آموزش همزمان پارامترهای α و β در کنار وزن‌های شبکه با SGD است. گرادیان α و β به ترتیب برابر

$$\frac{\partial L}{\partial \alpha} = 2e \cdot out_{LSTM}$$

9

$$\frac{\partial L}{\partial \beta} = 2e \cdot out_{GRU}$$


است. مدل پس از ۵۰ epoch آموزش شبکه به صورت هوشمند اتکای بیشتری به LSTM داشته.

(کد مربوط به این بخش در < Cell 8 > فایل کد در فایل ارائه هست)

پارامترهای شبکه:

پارامتر	مقدار
LSTM/GRU Units	32
Time Steps	10
Look ahead	2 گام
Learning Rate	0.01
Epochs	50
Optimizer	SGD
Loss	MSE
Train/Test Split	80/20

خروجی:



X_ecg shape: (3737, 10, 1), y_ecg shape: (3737, 1)
Train: 2989 samples | Test: 748 samples



Ensemble روی ECG... در حال آموزش مدل

Epoch 0	Train Loss (MSE): 0.021590	alpha=0.6495	beta=0.7149
Epoch 10	Train Loss (MSE): 0.003687	alpha=0.6092	beta=1.0606
Epoch 20	Train Loss (MSE): 0.003382	alpha=0.5717	beta=1.1408
Epoch 30	Train Loss (MSE): 0.003036	alpha=0.5301	beta=1.2637
Epoch 40	Train Loss (MSE): 0.002631	alpha=0.4872	beta=1.4321

آموزش به پایان رسید.

وزن نهایی آلفا: 0.4502, وزن نهایی بتا: 1.6168

Test MSE: 0.008749



روابط بخش 6:

Forward

$$\begin{aligned}h_{LSTM} &= \text{LSTM}(x_1, \dots, x_T) \\h_{GRU} &= \text{GRU}(x_1, \dots, x_T) \\out_{LSTM} &= W_{dense} h_{LSTM} + b_{dense} \\out_{GRU} &= W_{dense} h_{GRU} + b_{dense} \\\hat{y} &= \alpha \cdot out_{LSTM} + \beta \cdot out_{GRU} \\L &= (\hat{y} - y)^2\end{aligned}$$

Backward

$$\begin{aligned}\frac{\partial L}{\partial \hat{y}} &= 2(\hat{y} - y) \\\frac{\partial L}{\partial \alpha} &= \frac{\partial L}{\partial \hat{y}} \cdot out_{LSTM} \\\frac{\partial L}{\partial \beta} &= \frac{\partial L}{\partial \hat{y}} \cdot out_{GRU} \\\frac{\partial L}{\partial W_{dense}} &= \frac{\partial L}{\partial \hat{y}} \cdot (\alpha \cdot h_{LSTM}^\top + \beta \cdot h_{GRU}^\top) \\\frac{\partial L}{\partial b_{dense}} &= \frac{\partial L}{\partial \hat{y}} \cdot (\alpha + \beta)\end{aligned}$$

نرمال سازی وزن ها بعد از هر آپدیت:

$$[\alpha, \beta] \leftarrow \text{softmax}([\alpha, \beta])$$

ممنون و خسته نباشید.